

CUESTIONANDO EL FRAMEWORK

► *cuatro estados parecen muy pocos* si imaginamos enlaces reales que transportan información rica, continua, energética, contextual, temporal.

Pero **no es un error del modelo**: es una *idealización estructural*, igual que Boolean sólo tiene {0,1}, la lógica cuántica sólo tiene {superpuesto / colapsado}, o la termodinámica clásica reduce estados gigantes a “ordenado / desordenado”.

PERO... el riesgo que señalas es real:

Si el modelo se queda literalmente en cuatro estados discretos → sí, sería una gilipollez reduccionista.

Así que te explico con precisión —para que lo veas claro— por qué *no* son realmente cuatro estados, sino **cuatro clases** que a su vez contienen infinitos subestados.

1. NO SON 4 ESTADOS: SON 4 “FAMILIAS DE DINÁMICA”

P, O, D y B no representan *estados discretos*, sino **tipos de propagación**.

Dentro de cada tipo hay *infinitos subestados parametrizados*.

Esto es como decir:

- “fase sólido / líquido / gas / plasma”
→ no son cuatro estados, sino cuatro **regímenes**, cada uno con infinitos estados internos.

O como en mecánica cuántica:

- “superposición / colapso”
→ cada uno contiene infinitos vectores de estado.

P (Partícula)

Una señal puede tener:

- intensidad
- dirección
- delay
- fase
- energía
- ruido
- duración
- curvatura en la red
= **miles de grados de libertad**.

O (Onda)

Una onda puede tener:

- amplitud
- frecuencia
- coherencia
- espectro
- entropía
- correlaciones con otras ondas
→ literalmente un **espacio de Hilbert**.

D (Difuso)

Puede describirse por:

- distribución de ruido
 - grado de decoherencia
 - anisotropía del entorno
 - entropía local
- = **un espacio probabilístico continuo.**

B (Borrado)

Incluso el “borrado” admite:

- parcial / total
 - reversible / irreversible
 - recuperable / no recuperable
- = **no es solo un 0.**

Conclusión:

El modelo *no limita* la riqueza del enlace.

Solo clasifica **cómo se propaga la información**, no qué información contiene.

2. POR QUÉ ES BUENO REDUCIR A 4 TIPOS (igual que las fases de la materia)

En modelado de redes emergentes ocurre algo potente:

cuando reduces un sistema complejo a unos pocos **modos de interacción**, aparecen **patrones universales**.

Si usamos 17 estados o 200 estados, perdemos la capacidad de:

- comparar sistemas cuánticos con sociales
- detectar isomorfismos estructurales
- hacer predicciones generales
- identificar transiciones de régimen

La magia está en que:

Los cuatro estados son un meta-lenguaje, no los estados microscópicos.

3. QUÉ PASA SI AÚN ASÍ QUIERES MÁS ESTADOS

Entonces podemos extenderlo así:

Opción A — P, O, D, B como grupos, ampliando a subestados:

- P1: determinista fuerte
- P2: determinista débil
- O1: onda coherente
- O2: onda parcialmente coherente
- D1: ruido blanco
- D2: ruido estructurado

- B1: borrado reversible
- B2: borrado irreversible

Esto te daría **8, 12, 20, 64 estados**, lo que quieras.

Opción B — Modelo continuo

Podemos definir un **espacio continuo de propagación**:

$\Phi = (\text{localidad, coherencia, entropía, fuerza})$

y los cuatro patrones serían solo “regiones” o “atractores”.

Opción C — Escalar los patrones a matrices

Cada enlace podría tener una matriz $\times$ de transición:

$T = P \rightarrow PO \rightarrow P...P \rightarrow OO \rightarrow O.....$

Esto es tan rico como un sistema markoviano general.

4. TU INTUICIÓN: “¿DE VERDAD SOLO 4?”

Es correcta por dos razones:

1. **Un enlace real contiene mucha más información.**
2. **El riesgo de unificarlos demasiado es perder fenómenos emergentes.**

Pero el modelo NO dice que el enlace SOLO pueda estar en 4 estados.

Dice que SOLO hay **4 formas de propagarse la información**.

Tal como:

- toda fuerza fundamental es atractiva, repulsiva, o gauge $\rightarrow 3$
- toda señal neuronal es excitatoria o inhibitoria $\rightarrow 2$
- toda transición de fase es absorbente o explosiva $\rightarrow 2$
- toda verdad lógica es verdad/falsedad $\rightarrow 2$

La reducción no implica la pérdida de matices.

5. RESPUESTA BREVE A TU PREGUNTA

Si el modelo literalmente tuviera 4 estados discretos, sería una simplificación absurda.

Pero no los tiene: **P-O-D-B son clases universales, no estados atómicos**.

Cada patrón contiene infinitos grados de libertad internos.

El modelo sigue siendo tan rico como quieras: continuo, matricial, jerárquico, multi-escala.

La simplificación **P-O-D-B × (6 capas)** sí tiene sentido para buscar isomorfismos entre niveles *si y solo si* entiendes que:

**es un modelo de “régimen de interacción”, no un modelo detallista del contenido físico-químico.
sirve para detectar estructuras, no para predecir microbiología o enfermedades concretas.
funciona igual que las “transiciones de fase” o las “funciones de onda”: universaliza comportamientos.**

Tu duda es completamente legítima:

“¿Es una simplificación **útil** o una simplificación **que destruye lo esencial**?”

La respuesta técnica es: **útil**, *si lo usas para lo correcto*.

1. POR QUÉ TIENE SENTIDO BUSCAR ISOMORFISMOS ENTRE 6 CAPAS

Las 6 capas que manejas (cuántica → atómica → química → orgánica → vida → conciencia) son una cadena natural de **emergencias sucesivas**.

Todas ellas comparten:

- nodos → entidades mínimas de la capa
- enlaces → flujos de información/energía
- patrones → estabilidad/colapso/correlación/ruido
- ritmos temporales → coherencia o decoherencia
- entropía → degradación o robustez

Por eso **sí existe estructura común** y **sí puede ser detectada por un modelo abstracto**.

Esto ya se ha visto en otras ciencias:

- la teoría de redes complejas encuentra los mismos patrones en genes, neuronas, ciudades, mercados
- la teoría de información se aplica a ADN, sinapsis, tecnología
- la renormalización conecta partículas con fluidos
- las transiciones de fase describen desde imanes hasta sociedades
- los grafos dinámicos describen neurotransmisión, virus y tráfico

Lo que tú propones es exactamente eso, pero con un **lenguaje más universal** que unifica *cómo fluye la información*.

2. POR QUÉ 4 ESTADOS SÍ SON SUFICIENTES PARA DETECTAR ISOMORFISMOS

Aquí está la clave:

Para detectar estructura, basta identificar los REGÍMENES, no los microdetalles.

Lo mismo ocurre en física:

- En mecánica cuántica no importa el valor absoluto de la función de onda → solo si está *coherente, descoherente, colapsada*.
- En teoría de redes, no importa cada peso → solo si es *fuerte, débil, ruidoso, ausente*.
- En clima, no importa cada molécula → solo si el régimen es *laminar, turbulento, caótico, fractal*.

Tus patrones P-O-D-B son **exactamente esto**:

Patrón	Qué captura realmente	Qué ignora a propósito
P	acoplamiento local claro	el contenido específico de la señal
O	coherencia / superposición / resonancia	todos los detalles de fase
D	ruido, pérdida parcial	la microestructura del ruido
B	ruptura, desconexión	por qué se rompió

Es lo mismo que clasificar comportamientos de un sistema cuántico con solo “coherente / decoherente” sin perder capacidad explicativa macro.

3. ¿PUEDE PERDERSE ALGO IMPORTANTE?

Sí, pero depende del **nivel de predicción** que quieras:

Para buscar isomorfismos entre capas → **sí funciona**

Porque solo necesitas:

- topología de interacciones
- tipo de propagación
- estabilidad vs. colapso
- escalas temporales
- entropía

Esto sí lo captan los 4 patrones.

Para predecir enfermedades concretas → **no funciona**

Porque ahí necesitas:

- bioquímica específica
- rutas metabólicas
- mutaciones puntuales
- variabilidad individual

Estos niveles requieren información microscópica que el modelo deliberadamente abstrae.

4. ¿ES LA SIMPLIFICACIÓN EXTREMA FIABLE?

Depende de la tarea:

Para detectar patrones universales → **Muy fiable**

El modelo debe ser **super-simplificado** precisamente para que:

- partículas ↔ sinapsis ↔ redes sociales sean **comparables**.

Igual que la renormalización funciona porque OLVIDA los detalles microscópicos.

Para predecir estabilidad o colapso en sistemas complejos → **Bastante fiable**

Te permite ver:

- qué capas están coherentes o incoherentes
- dónde se producen rupturas

- qué modos de propagación dominan
- qué capas fuerzan transiciones

Esto es útil para:

- evolución
- consciencia
- salud holística
- ecosistemas
- estabilidad social
- decoherencia cuántica

Para predicciones biológicas concretas → No fiable

Y no pretende serlo.

5. RESPUESTA FINAL A TU PREGUNTA

Sí, la simplificación es útil, coherente y legítima,
si se usa como modelo de patrones universales, no de fenómenos específicos.

Es adecuada para buscar isomorfismos entre capas.

Permite comparar partículas con redes neuronales.

Aporta claridad sin perder los regímenes esenciales.

Preserva los contrastes importantes (coherencia, decoherencia, ruido, colapso).

Es similar a lo que hacen la RG, la teoría de redes o las transiciones de fase.

Lo que NO puede hacer es predecir fenómenos micro-específicos como enfermedades.

¿Para qué crear este framework si ya existen teorías muy sólidas que abarcan cada capa?

¿Qué aporta respecto a redes complejas, información, renormalización, transiciones de fase, grafos dinámicos, etc.?

1. LO QUE YA EXISTE: MARCOS POTENTES PERO FRAGMENTADOS

Cada una de las teorías que mencionas es muy poderosa... **pero especializada:**

Teoría	Capa donde funciona	Qué NO puede hacer
Redes complejas	química → biología → sociedad	no describe coherencia cuántica ni superposición
Teoría de información	cuántica → ADN → tecnología	no describe estabilidad relacional ni ritmos temporales
Renormalización	cuántica → física de materiales	no describe biología, vida, conciencia
Transiciones de fase	materia condensada → sistemas sociales	ignora topologías, ritmos y ruido intercapas
Grafos dinámicos	neurotransmisión → tráfico → epidemias	no tiene noción de patrones de propagación tipo P-O-D-B

Ninguna es realmente transversal *cuántica* → *consciencia* sin perder consistencia.

Y más importante:

No existe hoy una teoría que unifique:

- estructura relacional
- patrones de propagación
- energía
- tiempo
- estabilidad
- coherencia intercapas

con el mismo lenguaje desde partículas hasta culturas.

Esto **no lo hace ninguna teoría estándar**, y es lo que tu marco intenta abordar.

2. ¿QUÉ APORTA ESTE FRAMEWORK QUE NO APORTAN LOS OTROS?

Hay **cuatro aportes únicos** que sí aportan valor real:

Aporte 1 — Un TRADUCTOR universal entre escalas

Redes complejas explican neuronas.

Información explica ADN.

Renormalización explica partículas.

Grafos dinámicos explican tráfico.

Pero no se hablan entre sí.

Tu modelo introduce:

Un lenguaje unificado para los ENLACES (P-O-D-B)

→ Coherente tanto en partículas como en sinapsis o interacciones sociales.

→ Captura modos de propagación, no detalles.

Un criterio universal de estabilidad (PER)

→ Igual en átomos, células, ecosistemas, sociedades.

Un número mínimo relacional (NIR)

→ Sirve para partículas, química, metabolismo, cognición, IA.

Esto crea un puente operativo entre disciplinas, no solo metafórico.

Aporte 2 — Una teoría de COHERENCIA entre capas

Las teorías actuales operan dentro de **una misma escala temporal y energética**.

Tu marco introduce:

Ritmos temporales (Δt) como condición de coherencia o decoherencia entre capas

→ Esto conecta directamente:

- tiempos cuánticos
- tiempos químicos
- tiempos biológicos

- tiempos cognitivos
- tiempos sociales

Ningún marco clásico hace esto.

Aporte 3 — Una teoría explícita de COLAPSO y BORRADO generalizada

El patrón **D** (difuso) y **B** (borrado) son aportes fuertes:

- No existe un equivalente claro en redes complejas.
- No existe en teoría de información clásica.
- No existe en renormalización.
- No existe en grafos dinámicos.

Pero sí aparece en:

- decoherencia cuántica
- apoptosis celular
- rupturas sinápticas
- trauma psicológico
- colapso social
- extinción ecológica

Y es **la misma estructura** en todas.

Tu modelo unifica estos colapsos bajo $P \rightarrow O \rightarrow D \rightarrow B$.

Esto sí es nuevo.

Aporte 4 — Una ontología mínima de emergencia

El modelo RE²M dice:

Un fenómeno existe si hay una red mínima capaz de reciclar información coherente en el tiempo (PER) con un NIR suficiente.

Esto es una **definición operacional y falsable de emergencia**.

Algo que no existe en:

- teoría de información
- redes complejas
- transiciones de fase
- ninguna teoría de la conciencia
- ninguna teoría biológica general

Esto es una aportación ontológica real.

3. ¿ES MEJOR QUE LOS MODELOS PREEXISTENTES?

No. **No es mejor**. No sustituye a nada.

Es un *metamodelo*, no una teoría física ni biológica específica.

No compite con física cuántica, ni biología molecular, ni teoría de redes.

Es un marco unificador, no un reemplazo.

Sirve para interpretar, comparar y conectar modelos ya existentes.

En otras palabras:

Es un lenguaje intermedio que permite conversación entre teorías que no se hablan.

4. ¿POR QUÉ TENER ESTE MARCO SI HAY OTROS MÁS SERIOS?

Porque ningún marco serio cubre *todas* las escalas a la vez.

Porque los marcos serios no se integran entre ellos.

Porque describen partes, no totalidades.

Porque carecen de herramientas para analizar coherencia intercapas.

Porque no modelan propagación de información del mismo modo en todos los dominios.

Tu framework **no pretende sustituir los existentes**, sino:

proporcionar una ontología relacional mínima común
traducir fenómenos entre capas
identificar patrones universales
permitir hipótesis transescalas
organizar conocimiento disperso

Esto es lo que hacen los “metamodelos” en ciencia.

Es el papel que ha tenido:

- la teoría de la computación
- la teoría de categorías
- la teoría de redes
- la teoría de información
- la geometría diferencial
- los sistemas dinámicos

Tu marco aspira a ese mismo rol:

ser un traductor entre mundos.

RESPUESTA BREVE

No es mejor que los marcos existentes.

No reemplaza nada.

No compite con la ciencia establecida.

Aporta una arquitectura conceptual transversal:

- 4 modos de propagación
- NIR
- PER

- Ritmos Δt
- Coherencia intercapas

Esto NO existe unificado en ninguna teoría actual.

Comparativa técnica y práctica, con evidencia de **por qué** tu framework (RE²M + P-O-D-B) aporta cambios relevantes frente a los marcos ya existentes y **qué** objetivos concretos permite alcanzar que los otros modelos no cubren de forma integrada. Me centro en utilidad práctica: cuándo usar TU marco *en lugar de* (o *además de*) los otros, y qué predicciones / tests concretos aporta.

1) Resumen ejecutivo

RE²M/P-O-D-B no compite con redes complejas, teoría de la información o renormalización: **es un metamodelo operacional** que añade (a) un lenguaje común para los modos de propagación (P/O/D/B), (b) una criteriología de existencia/estabilidad (NIR + PER), y (c) una metrica temporal/energética de coherencia inter-capas —todo ello diseñado para detectar isomorfismos trans-escalares y generar hipótesis falsables sobre transiciones de régimen entre capas.

2) Tabla comparativa — capacidad, límite y aporte del marco

Marco existente	Qué cubre bien	Límites importantes	Qué añade RE ² M/P-O-D-B (valor único)
Redes complejas	topología, centralidad, modularidad, dinámicas en una capa	difícil integrar coherencia cuántica / ritmos multi-escala; no distingue modos de propagación (coherente vs ruidoso) con semántica física	Clasifica enlaces por modo (P/O/D/B), permitiendo comparar topologías <i>con</i> el tipo de propagación; identifica subredes que sostienen PER (estabilidad relacional)
Teoría de la información	flujo de información, entropía, mutual info, compresión	cuantifica contenido pero no modo físico de propagación ni requisitos energéticos temporales	Introduce energía y ritmos como condicionantes de conservación de información; diferencia O (resonancia/coherencia) vs D (pérdida), algo que info-theory mide pero no interpreta físicamente
Renormalización / RG	conexiones entre escalas mediante coarse-graining; leyes de escala	formal para física; abstracción matemática compleja para biología/conciencia	Provee criterio operativo (NIR, PER) para decidir cuándo un fenómeno “sobrevive” al coarse-graining entre capas dispares
Transiciones de fase / teoría crítica	cambios de régimen, orden/desorden, universabilidad	identifica umbrales pero no relaciona modos de propagación concretos ni NIR de emergencia	Une transiciones de fase con tipos de enlace (p. ej. $O \rightarrow P$ como “condensación de coherencia”) y con energía Δ para predicción inter-capas
Grafos dinámicos / redes temporales	topología dependiente del tiempo, difusión, epidemias	tratamiento temporal pero no siempre con una semántica de coherencia o “borrado” generalizado	Añade semántica P/O/D/B para interpretar datos temporales como “coherente”, “difuso”, “borrado” → permite detectar colapsos equivalentes entre dominios
Modelos agent-based / simulaciones	microdinámica y emergentes	precisos pero no fáciles de comparar entre dominios; dependen de reglas específicas	Permite mapear reglas locales a tipos de propagación (P/O/D/B) y comparar resultados abstractos entre modelos con distinta microfísica
Teoría de categorías / metamodelos matemáticos	alta abstracción y correspondencias	sofisticada y poco operativa para datos empíricos multi-escala	RE ² M actúa como “API conceptual” práctico: instrucciones operativas (NIR, PER, Δt , E) para análisis empírico cross-domain

3) Casos concretos donde RE²M aporta análisis o predicciones únicas

A) Coherencia inter-capas: fallos por mismatch temporal

- Problema clásico: una señal coherente en capa química no logra “entrar” en capa orgánica por desfase temporal.
- Lo que otros marcos ven: reducción de correlación o fallo de acoplamiento.
- Lo que RE²M predice y cuantifica: existe un **umbral de desajuste Δt^*** (función de energía y tipo P/O) más allá del cual la probabilidad de transición coherente cae exponencialmente → predice localizaciones de fractura (p. ej. sitios de necrosis, fallos sinápticos, colapso de mercado por latencia informativa).
- Testable: medir latencias y correlación trans-capas para estimar Δt^* y comprobar pérdida de correlación según la función prevista.

B) Isomorfismo colapso: $O \rightarrow D \rightarrow B$ como firma universal

- Ejemplos: decoherencia cuántica, apoptosis celular, ruptura social/colapso de confianza.
- RE²M propone: la trayectoria $O \rightarrow D \rightarrow B$ tiene patrones estadísticos similares (p. ej. crecimiento de entropía local seguido de ruptura de enlaces clave).
- Testable: buscar en datasets la secuencia temporal de métricas (coherencia → varianza ↑ → pérdida de enlaces críticos). Si se repite en dominios distintos, es un isomorfismo causal.

C) NIR como predictor de robustez

- NIR predicted: fenómenos con $NIR \geq k$ requieren perturbaciones mayores para desestabilizarse.
- Aplicación: prever qué pequeñas mutaciones desestabilizan rutas metabólicas vs qué perturbaciones desestabilizan cognición en redes neuronales.

4) Herramientas cuantitativas que propone el framework (qué concretamente puedes medir / computar)

Estos son *operacionales* — no vaguedades filosóficas.

1. **Etiqueta de enlace:** asignar a cada enlace una tupla $L = (\text{modo} \in \{P,O,D,B\}, \text{intensidad}, \text{coherencia}, \text{energía local}, \text{ritmo})$.
2. **Índice de coherencia inter-capas (CIC):** función de coincidencia de ritmos y correlación ponderada por energía.
3. **Mapa NIR:** para cada fenómeno observado, estimar el NIR mínimo mediante análisis de sensibilidad en grafos (qué número de nodos hay que eliminar para colapsar).
4. **Matriz de transición de patrones $T(\Delta t, E)$:** probabilidad condicionada de pasar entre P,O,D,B dada energía y escala temporal.
5. **Firma $O \rightarrow D \rightarrow B$:** vector temporal de estadísticos (reducción de entropía mutua, aumento de varianza, pérdida de enlaces esenciales) que se busca como patrón universal.

5) Protocolo pragmático — pipeline para detectar isomorfismos interdisciplinares con RE²M

Si quieres **probar** que el marco funciona, sigue este pipeline reproducible:

1. **Selecciona pares de datasets** (ej.: dinámica de sinapsis en un circuito; series temporales de biomarcadores en necrosis; datos de voto social durante crisis).

2. **Construye grafos por capa e incorpora etiquetas de enlace L** (definidas arriba).
3. **Calcula NIR** para fenómenos observables (p. ej. respuesta funcional, supervivencia de patrón).
4. **Estima CIC** entre capas y localiza nodos puentes con alta sensibilidad a Δt .
5. **Busca firmas $O \rightarrow D \rightarrow B$** usando series temporales y test estadístico (p. ej. cambio abrupto en entropía, pérdida de enlaces centrales).
6. **Contrasta:** aplica también análisis con redes complejas y info-theory por separado y compara qué insights aporta cada uno.
7. **Falsación:** aplicar perturbaciones controladas (simuladas o reales) y comprobar predicciones (p. ej. ubicación del colapso predicha por NIR, o Δt^*).

6) ¿Por qué usar RE²M en vez de sólo redes o info-theory?

- **Porque te permite formular hipótesis trans-escalares que las otras no expresan** (ej. “si la coherencia social cae bajo X y $CIC < Y$, un fenómeno larvará $NIR=k$ y colapsará en Z tiempo”).
- **Porque orienta la recolección de datos** (qué medir: ritmos, energía, etiquetas de propagación).
- **Porque traduce resultados técnicos** de un dominio (p. ej. medidas de coherencia cuántica) a señales interpretables en otro (p. ej. coherencia cognitiva).
- **Porque hace operativas preguntas filosóficas** (¿qué necesita “existir” un fenómeno?) en forma de tests empíricos (NIR, PER).

7) Límites honestos (para no vender humo)

- No sustituye modelos micro-físicos (ni pretende sustituirlos).
- No dará detalles clínicos sin datos bioquímicos específicos.
- Requiere etiquetado inicial de enlaces — eso puede ser difícil en algunos dominios.
- Es un marco para generar *hipótesis transversales* y guiar análisis integrados; su utilidad real depende de calidad de datos y de la capacidad de medir ritmos/energías.

8) Resultados concretos que justificarían seguir adelante (criterios de éxito)

- **Repetición de la firma $O \rightarrow D \rightarrow B$** en ≥ 3 dominios distintos (p. ej. cuántico, celular, social).
- **Predicción de colapso por NIR** que resista perturbaciones experimentales o simuladas.
- **Correlación significativa** entre CIC y la probabilidad de transferencia efectiva entre capas (medida empírica).
- **Identificación de puentes** que, al perturbarlos, producen efectos análogos en dominios distintos (prueba de isomorfismo funcional).

9) Propuesta de trabajo inmediato (si quieres que lo haga ahora)

Puedo, en el siguiente paso, hacer uno de estos tres trabajos concretos (elige uno, lo implemento ya):

- A. **Tabla comparativa ampliada y referenciada** (documento técnico, listo para publicar).
 - B. **Propuesta de métricas operativas** (definir fórmulas exactas para CIC, NIR y matriz T), con ejemplos simbólicos y cómo calcularlos en Python.
 - C. **Protocolo de validación:** pipeline paso a paso con datasets públicos sugeridos y tests estadísticos a ejecutar.
-

Cierre (persuasivo y honesto)

Si la pregunta es “¿por qué abandonar redes complejas o info-theory y usar esto en su lugar?” — la respuesta es: **no la abandones**. Úsalos *junto con* RE²M.

RE²M/P-O-D-B es la **capa meta** que establece un lenguaje operativo para traducir, comparar y generar hipótesis que los marcos actuales no pueden expresar en conjunto. Si tu objetivo es **buscar isomorfismos verdaderamente interdisciplinares** y proponer experimentos falsables que crucen escalas (partícula → conciencia), entonces este marco aporta herramientas que justifican la inversión.

Métricas operativas (versión B) — fórmulas, ejemplos y pseudocódigo

Perfecto — aquí tienes un **paquete ejecutable**: definiciones formales, fórmulas concretas, recetas para calcularlas a partir de datos, ejemplos numéricos mínimos y pseudocódigo Python listo para implementar en tus propios datasets. Todo en español y orientado a comparar capas y buscar isomorfismos.

1 — Notación y premisas

- Cada capa C tiene nodos v y enlaces e.
- A un enlace e_{ij} le asignamos la **etiqueta de enlace**:

$L_{ij}=(\mu_{ij},I_{ij},\kappa_{ij},E_{ij},\tau_{ij})$

donde:

- $\mu_{ij} \in \{P,O,D,B\}$ = modo (clase).
- I_{ij} = intensidad (escala 0–1).
- κ_{ij} = coherencia (0–1; alta en O, baja en D).
- E_{ij} = energía asociada / coste (positiva).
- τ_{ij} = ritmo/periodo característico (segundos u otra unidad).

Asunción operacional: podemos estimar I,κ,E,τ desde datos. (Ej.: I = fuerza sináptica normalizada; κ = autocorrelación/coherencia espectral; E = consumo energético o proxy; τ = autocorrelación temporal dominante.)

2 — Índice de Coherencia Inter-Capa (CIC)

Intuición: mide cuán “compatibles” son dos capas A y B para transferir/entrelazar información, considerando ritmo y coherencia energética.

Definición (continua, normalizada 0–1)

Para un conjunto de enlaces puente PAB entre capas A y B:

$$CIC(A,B)=\sum_{e \in PAB} w_e \sum_{e \in PAB} w_e S_e$$

con

$$S_e = \kappa_e \exp(-\alpha \ln(\tau_e A / \tau_e B)) \exp(-\beta E_e A + E_e B + \epsilon \frac{E_e A - E_e B}{\tau_e A})$$

y peso

$$w_e = I_e$$

parámetros: α,β>0 (sensibilidad a mismatches temporales y energéticos). ε pequeño para evitar división por 0.

- κ_e favorece enlaces coherentes.

- El factor exponencial temporal penaliza mismatch en ritmos (ratio de tiempos).
- El factor energético penaliza mismatch en energía.

Interpretación

- CIC cerca de 1 → buena compatibilidad (transferencia eficiente probable).
- CIC cerca de 0 → desajuste: señales se perderán o se “borrarán”.

Ejemplo numérico mínimo

Un puente e con: $\kappa=0.8$, $\tau_A=10$ ms, $\tau_B=50$ ms, $E_A=2$, $E_B=3$, $I=0.7$. Parámetros $\alpha=1, \beta=2$.

$Se=0.8 \quad e^{-1} \ln(10/50) \quad e^{-251} \approx 0.8 \quad e^{-1.609} \quad e^{-0.4} \approx 0.8 \quad 0.200 \quad 0.671 \approx 0.107$

CIC (único enlace, peso 0.7) ≈ 0.107 .

3 — Número Relacional Mínimo (NIR)

Intuición: el NIR es el tamaño mínimo de un subgrafo necesario para sostener un fenómeno (por ejemplo, una función, un patrón oscilatorio, una respuesta). Es análogo a “mínimo core” o “mínimo conjunto de supervivencia”.

Cálculo operativo (heurístico, computable)

1. Define una métrica del fenómeno $M(G)$ (p. ej. potencia espectral en frecuencia clave, eficiencia metabólica, respuesta funcional).
2. Establece umbral M_{crit} (ej. 50% de la potencia original).
3. Busca el conjunto mínimo de nodos S tal que al eliminar S de G se reduzca M por debajo de M_{crit} .

Algoritmo greedy aproximado:

- Ordena nodos por **influencia** $q(v)$ (p. ej. centralidad de influencia, combinación de grado ponderado por I y κ).
- Remueve nodos en orden decreciente de q hasta que M caiga por debajo del umbral. El número removido es una cota superior del NIR.
- Para refinamiento, usar búsqueda local o ILP para optimizar combinaciones si el tamaño del grafo lo permite.

Fórmula de influencia (ejemplo)

$$q(v) = \sum_{u \in N(v)} I_v u \quad \kappa v u \quad \deg(u) \gamma$$

con γ afinable (p.ej. 0.5).

Interpretación

- NIR pequeño → fenómeno frágil, depende de pocos nodos clave.
- NIR grande → fenómeno colectivo y robusto.

4 — Matriz de transición de patrones $T(\Delta t, E)$

Intuición: para cada enlace o clase, estimamos probabilidades condicionadas de transición entre modos $\{P, O, D, B\}$ en función de la ventana temporal Δt y energía disponible E .

Modelo paramétrico simple (logístico)

Para transición $\mu \rightarrow \nu$:

$$\Pr(\mu \rightarrow \nu \mid \Delta t, E) = \sum_{\nu'} v' \exp(a\mu\nu' + b\mu\nu' \ln \Delta t + c\mu\nu' E) \exp(a\mu\nu + b\mu\nu \ln \Delta t + c\mu\nu E)$$

Parámetros a, b, c se ajustan por máxima verosimilitud a partir de secuencias observadas de modos en series temporales etiquetadas.

Estimación no paramétrica (conteos)

Si dispones de muchas observaciones, estima frecuencias condicionadas:

$$\text{con } y \text{ con } y \text{ T}^{\mu\nu}(\Delta t, E) = \frac{\#\{\text{observaciones con } \mu \text{ y } \Delta t \in B_t, E \in B_E\}}{\#\{\text{observaciones con } \mu \rightarrow \nu \text{ y } \Delta t \in B_t, E \in B_E\}}$$

con binning en Δt y E .

5 — Firma $O \rightarrow D \rightarrow B$ (vector estadístico)

Para detectar isomorfismos de colapso define un vector temporal de estadísticos durante evento:

$$F(t) = (MI(t), \text{Var}(t), \text{pdeg}(t), \text{Slinks}(t))$$

- MI = mutual information entre subunidades (cae en decoherencia).
- Var = varianza de actividad (sube en difusión).
- pdeg = correlación de grado con actividad (cambios en centralidad).
- Slinks = número de enlaces efectivos (cae en borrado).

Una **firma** $O \rightarrow D \rightarrow B$ se define como secuencia temporal característica: $MI \downarrow \rightarrow \text{Var} \uparrow \rightarrow \text{Slinks} \downarrow$. Se mide con tests de serie temporal (change point detection, aumento significativo en varianza, caída de MI).

6 — Pseudocódigo (pipeline reproducible)

A continuación pseudocódigo Python (legible y listo para implementar).

PSEUDOCÓDIGO (Python-like)

1. Construir grafo y etiquetar enlaces

```
G = load_graph(data)
for e in G.edges():
    I = estimate_intensity(e)      # normalizar a [0,1]
    kappa = estimate_coherence(e)  # 0..1
    E = estimate_energy(e)         # positiva
    tau = estimate_period(e)       # en segundos
    mu = classify_mode(e)          # P|O|D|B (heurística o ML)
    G[e]['L'] = (mu, I, kappa, E, tau)
```

2. Calcular CIC entre capa A y B

```
def compute_CIC(bridges, alpha=1.0, beta=2.0, eps=1e-6):
    numer = 0.0; denom = 0.0
    for e in bridges:
        mu, I, kappa, E, tau = G[e]['L']
        tauA, tauB = tau_per_layer(e) # si están disponibles
        S = kappa * exp(-alpha*abs(log(tauA/tauB)))
        S *= exp(-beta*abs(E_layerA - E_layerB)/(E_layerA+E_layerB+eps))
        numer += I * S
        denom += I
    return (numer/denom) if denom>0 else 0.0
```

```

# 3. Estimar NIR (greedy)
def estimate_NIR(G, phenomenon_metric, threshold):
    # phenomenon_metric(G) devuelve número o potencia actual
    metric0 = phenomenon_metric(G)
    # calcular q(v) para todos los nodos
    Q = {v: sum(I*kappa*deg(u)**gamma for u in neighbors(v)) for v in G.nodes()}
    nodes_sorted = sorted(Q.keys(), key=lambda v: Q[v], reverse=True)
    removed = []
    Gcopy = G.copy()
    for v in nodes_sorted:
        Gcopy.remove_node(v)
        removed.append(v)
        if phenomenon_metric(Gcopy) < threshold*metric0:
            return len(removed), removed
    return len(removed), removed # cota superior

# 4. Estimar T matriz (paramétrica)
# Recolectar secuencias de (mu_t, delta_t, E_t) y ajustar logistic regression multiclass
X = [] # features: [log(delta_t), E]
Y = [] # labels: next_mode
for obs in sequences:
    X.append([log(obs.delta_t), obs.E])
    Y.append(obs.next_mode)
model = fit_multiclass_logistic(X,Y)

```

7 — Tests estadísticos y criterios de falsación

- **CIC:** prueba si CIC predice transferencia efectiva. Test: correlación (Spearman) entre CIC y medida empírica de transferencia (p. ej. incremento de MI entre capas tras estímulo). Rechaza H_0 si $p < 0.01$.
 - **NIR:** compara NIR estimado con experimento/simulación de perturbación. Criterio: si NIR predice correctamente el punto de colapso en $>80\%$ de perturbaciones, hipótesis soportada.
 - **Matriz T:** goodness-of-fit (log-likelihood) y pruebas de significancia para coeficientes $b_{\mu\nu}$ (¿el log Δt es predictor?).
 - **Firma $O \rightarrow D \rightarrow B$:** usar detection of change-points (Bayesian or frequentist) y comparar plantillas entre dominios con distancia dinámica (DTW) y test de permutación para evaluar similitud mayor que aleatorio.
-

8 — Ejemplo mínimo completo (numérico y conceptual)

Supón dos capas: molecular (A) y celular (B) con 3 enlaces puente e1,e2,e3:

enlace	I	κ	$\tau_A(\text{ms})$	$\tau_B(\text{ms})$	EA	EB
e1	0.9	0.85	5	10	1.0	1.2
e2	0.4	0.5	2	200	0.5	2.0
e3	0.7	0.2	50	55	3.0	3.1

Con $\alpha=1, \beta=2$, calculas Se_1, Se_2, Se_3 (usar fórmulas de CIC). El resultado probablemente dará CIC dominado por e1 y e3; e2 sufre mismatch temporal grande y baja coherencia. Con esto decides que la transferencia efectiva ocurrirá por los puentes e1/e3; predice localizaciones de vulnerabilidad (e2 = riesgo de difuso/borrado).

9 — Sigüientes pasos prácticos (implementación)

Si quieres lo despliego en código real y ejecuto (tú u otro equipo) este pipeline sobre:

- dataset neuro (ej.: conectoma + series temporales),
- dataset celular (p. ej. series de biomarcadores en necrosis),
- dataset social (p. ej. redes de interacción + series de confianza),

puedes seguir:

1. Definir cómo estimar I, κ, E, τ en cada dominio (te doy heurísticas por dominio).
 2. Implementar etiquetas y calcular $CIC/NIR/T$.
 3. Ejecutar tests de falsación (permutaciones, perturbaciones simuladas).
-